


# ***Bases de Données Avancées***




**Ioana Ileana**  
*Université Paris Descartes*

Cours basé sur le livre (et les diapositives de):  
Database Management Systems 3ed, R. Ramakrishnan et J. Gehrke




# *Cours 1: Intro / rappels SGBD*




- ❖ Diapos traduites et adaptées du matériel fourni en complément du livre Database Management Systems 3ed, par Ramakrishnan et Gehrke ; un grand merci aux auteurs pour la réalisation et la disponibilité de ce matériel !
- ❖ Les diapos originales (en anglais) sont disponibles ici :  
<http://pages.cs.wisc.edu/~dbbook/openAccess/thirdEdition/slides/slides3ed.html>
- ❖ Plus particulièrement, ce cours touche aux éléments dans le Chapitres 1 et 8 du livre ci-dessus

# Qu'est-ce qu'un SGBD?




- ❖ Base de données (BD): une grande collection de données « intégrées » / « reliées »
  - Qui modélise souvent des entreprises et organisations
    - Entités (étudiants, cours, produits, clients)
    - Associations (un étudiant s'inscrit dans un cours, un client achète un produit...)
- ❖ Un Système de Gestion de Bases de Données (SGBD), en anglais DBMS (Database Management System) = ensemble logiciel conçu pour stocker et gérer les bases de données

# *Pourquoi pas des fichiers tout simplement?*



- ❖ Une application concernée par la gestion des données devrait assurer / comporter:
  - Le déplacement de préférence efficace ;) de gros volumes de données entre la RAM et le disque
  - Du code spécifique pour différents types de requêtes (en: queries) sur les données
  - La protection de la consistance / cohérence des données en cas d'accès concurrent / utilisateurs multiples
  - La récupération / le rétablissement des données en cas de pannes / incidents / « plantages » (en: crashes)
  - La sécurité et le contrôle d'accès aux données suivant le spécifique et la granularité de ces données
- ❖ → Les fonctionnalités fournies par le système de fichiers = souvent inadaptées ou insuffisantes!

# Avantages d'un SGBD



## ❖ Indépendance des données

- Les applications ne sont pas concernées par les détails de la représentation / du stockage des données

## ❖ Accès efficace

- Tout un tas de techniques spécialisées / sophistiquées..

## ❖ Intégrité et sécurité des données

## ❖ Administration uniforme des données


## ❖ Gestion de l'accès concurrent et de la reprise / récupération après panne / incident (crash recovery).

## ❖ Moins de temps de développement applicatif

- Et moins de temps passé à réinventer la roue ;)


• *Désavantages / limitations ?*

# Modèles de Données




- ❖ Un modèle de données (en: data model) est un ensemble de concepts utilisés pour décrire des données
  - Censé cacher beaucoup des détails « bas-niveau » du stockage
- ❖ Un schéma (en: schema) est une description d'un ensemble (jeu) de données spécifique, qui s'appuie sur un modèle de données
- ❖ Le modèle relationnel (en: relational model) reste le modèle de données le plus utilisé de nos jours
  - Concept principal: la Relation
    - Table avec des lignes et des colonnes
    - Les lignes sont appelées aussi tuples, ou enregistrements (records) ; les colonnes sont aussi appelées champs
    - Chaque relation a un schéma, comprenant son nom et la description de ses colonnes (nom, type)
  - **Ce cours se focalisera sur le modèle relationnel et les SGBD relationnels (SGBDR ; en: RDBMS)**

# Les 3 niveaux d'abstraction d'un SGBD(R)




❖ Plusieurs vues (groupées dans des “schémas externes”), un schéma conceptuel (logique) et un schéma physique.

- Les vues décrivent comment les utilisateurs voient les données.
- Le schéma conceptuel définit la structure logique (les relations ds la BD ...).
- Le schéma physique définit les détails du stockage - les fichiers et indexes utilisés...



- Les schémas sont définies avec un DDL
- Les données sont modifiées / interrogées avec un DML.




# *Exemple: La BD (relationnelle) d'une université*

- ❖ Schéma conceptuel / logique :
  - Etudiants (*eid: string, enom: string, login: string, age: integer, moyenne: real*)
  - Cours (*cid: string, cnom: string, credits: integer*)
  - Inscrits (*eid: string, cid: string, note: string*)
- ❖ Schéma physique :
  - Relations stockées en tant que fichiers non-triés
  - Index sur la première colonne de *Etudiants*
- ❖ Schéma externe: vue Info\_cours
  - Info\_cours (*cid:string, nb\_inscrits:integer*)




# *L'indépendance des données \**



- ❖ Les applications sont “isolées”, séparées de la manière dont les données sont structurées et stockées
  - Et des changements dans cette structuration !
- ❖ Indépendance logique des données: protection par rapport aux changements dans la structure *logique* des données (ex. rajout d'une colonne)
  - À l'aide de l'abstraction offerte par les schémas externes
- ❖ Indépendance physique des données: Protection par rapport aux changements dans la structure *physique* des données (ex. trier le fichier)
  - Le rôle du schéma logique !


*\*Un des plus importants avantages dans l'utilisation d'un SGBD!*



# *Le contrôle de la concurrence*


- ❖ L'exécution concurrente / “parallèle” des programmes utilisateur est essentielle pour la performance d'un SGBD
  - Les accès disque sont fréquents et relativement lents, il est donc important de garder le CPU actif en faisant tourner plusieurs programmes utilisateurs de manière concurrente!
- ❖ Mais “entrelacer” les actions de plusieurs programmes utilisateurs peut causer de l'inconsistance ! (ex. chèque encaissé pendant que le solde du compte est en train d'être calculé...)
- ❖ Le SGBD garantit que de tels problèmes d'inconsistance ne surviennent pas!
  - Chaque utilisateur peut considérer qu' « il est seul à interagir avec le SGBD » - pas besoin de « se synchroniser en amont » ou de prendre en compte qui d'autre modifie les données !

# La transaction: l'exécution d'un programme BD




- ❖ Concept clé: la transaction = une séquence *atomique* d'actions sur la BD: lectures (reads) / écritures (writes).
- ❖ Chaque transaction, à la fin de son exécution, doit laisser la BD dans un état consistant - si la BD était consistante au début de la transaction.
  - Les utilisateurs peuvent spécifier des contraintes d'intégrité sur les données, et le SGBD garantira le respect de ces contraintes
  - Outre cela, le SGBD ne saura pas “comprendre” la sémantique des données (ex. comment les intérêts sur un compte sont calculés...)
  - → S'assurer qu'une transaction (exécutée toute seule) préserve la consistance est en fin de compte la responsabilité de *l'utilisateur!*

# Gestion / ordonnancement des transactions concurrentes





- ❖ Le SGBD garantit que l'exécution concurrente de  $\{T_1 \dots T_n\}$  est équivalente à une exécution sériale  $T_1' \dots T_n'$  en utilisant des protocoles de verrouillage (locking protocols)
- ❖ Esquisse du fonctionnement d'un protocole de verrouillage :
  - Avant de lire / écrire un objet, une transaction demande un verrou (lock) sur l'objet, et attend que le SGBD lui donne le verrou. Tous les verrous sont libérés / rendus (released) à la fin de la transaction.
  - **L'idée derrière:** Si une action de  $T_i$  (ex: écrire X) affecte  $T_j$  (qui lit X), une des deux transactions - par ex  $T_i$ , aura d'abord le verrou de X, forçant ainsi  $T_j$  à attendre la fin de  $T_i$ ; ceci induit un ordonnancement des transactions.
  - Mais que se passe-t-il si  $T_j$  a déjà verrouillé Y et  $T_i$  demande plus tard un verrou sur Y? : (**Deadlock!**)  $T_i$  ou  $T_j$  sera annulée (aborted) et redémarrée (restarted)!



# Atomicité des transactions

- ❖ Le SGBD garantit *l'atomicité* ("tout-ou-rien") d'une transaction même si crash au milieu de la transaction
  - Dans ce dernier cas, l'état de la BD sera retabli
- ❖ *Idée*: Garder un journal (log) (historique) de toutes les actions / modifications:
  - *Avant* qu'un changement soit fait dans la BD, l'entrée correspondante dans le journal est « sauvegardée » dans un endroit « sûr » (WAL : Write Ahead Log)
  - Après un crash, les effets des transactions qui n'ont été que partiellement exécutées sont défaits / annulés en utilisant le journal (grâce à WAL, si l'entrée correspondante du journal n'a pas été sauvée avant le crash, c'est que l'action n'a pas été faite sur la BD!)


# Le journal (log)




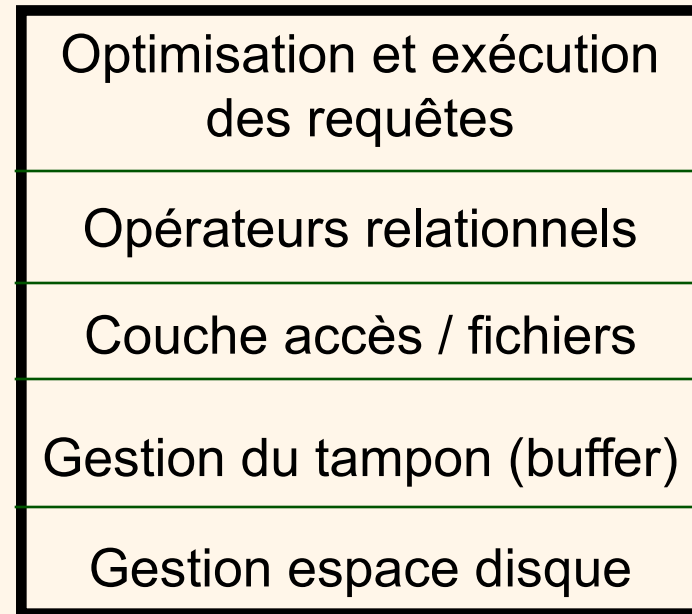
- ❖ Exemples d'actions / détails enregistrés dans le journal:
  - *Ti écrit un objet*: L'ancienne valeur et la nouvelle valeur
  - *Ti finit (commit) / est annulée (abort)*: Une entrée de journal correspondant à l'action
- ❖ Les entrées de journal comprennent l'ID de la transaction, ce permet d'annuler les effets d'une transaction (y compris en cours, dans le cas d'un deadlock !)
- ❖ Toutes les actions liées au journal (et au contrôle de la concurrence, comme le verrouillage / déverrouillage) sont gérées de manière transparente par le SGBD!


# Structure d'un SGBD

Ces couches  
sont concernées  
par le contrôle de  
la concurrence et la  
reprise après crash



- ❖ Un SGBD(R) typique a une architecture “en couches” (niveaux, en: layers ).
- ❖ La figure n'illustre pas les éléments de gestion de la concurrence et de reprise après crash
- ❖ Aussi, c'est une des architectures possibles; chaque système aura ses propres spécificités et variations!





# Structure d'un SGBD

- ❖ La requête utilisateur, après parsing, est présentée à l'optimiseur, qui produit un *plan d'exécution de la requête* (arbre d'opérateurs relationnels)
- ❖ Les opérateurs relationnels sont « des briques d'exécution » qui font à leur tour appel à la couche accès / fichiers
- ❖ Plus bas niveau encore, on retrouve le gestionnaire du tampon (buffer) et le gestionnaire de l'espace disque
- ❖ Nous allons examiner tous ces aspects dans les cours suivants, en commençant par les trois couches « en bas de la pile »

